CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN) · ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL · COMPUTACIÓN EN LA NUBE · ACA 1

Ingesta, vectorización y almacenamiento vectorial en la nube para un asistente RAG clínico

Embeddings locales con Ollama + EmbeddingGemma y búsqueda semántica en Supabase pgvector, a costo cero

Juan Reyes
Docente: Hamilton Rivera Flor
Noviembre de 2026

Pilar: Salud

1 Objetivo general

Diseñar e implementar una arquitectura cloud de ingesta, fragmentación, generación de embeddings y almacenamiento semántico en una base de datos vectorial gestionada, integrando metadatos de datasets clínicos con un corpus de guías y protocolos de salud.

2 Situación problema

¿Cómo estructurar un pipeline de datos no estructurados en la nube, con bases vectoriales serverless y modelos de embeddings abiertos, que recupere información clínica con alta precisión, costo cero y baja latencia?

La información clínica está dispersa en guías extensas y en tablas; buscar por palabras clave no capta el significado de la pregunta.

3 Enfoque: asistente de consulta clínica

- Responder sobre criterios diagnósticos, tamización y protocolos.
- Aportar evidencia de los datos (prevalencias, diferencias entre grupos).
- Proteger el texto clínico: el modelo de embeddings corre en el equipo; a la nube solo viajan vectores.

4 Corpus documental y datasets base

Guía de riesgo cardiovascular
Dolor torácico, presión arterial, prueba de esfuerzo, gammagrafía con talio, signos de alarma (OMS HEARTS).

Guía de cáncer de mama
Tamización, BI-RADS, BACAF y biopsia con aguja gruesa (GPC MinSalud 2013).

Protocolo de bioseguridad y consentimiento
5 momentos OMS, cortopunzantes, accidente biológico, Ley 1581 de 2012.

UCI Heart Disease · 920 pacientes
14 variables clínicas; diagnóstico angiográfico (num). 55 % con enfermedad.

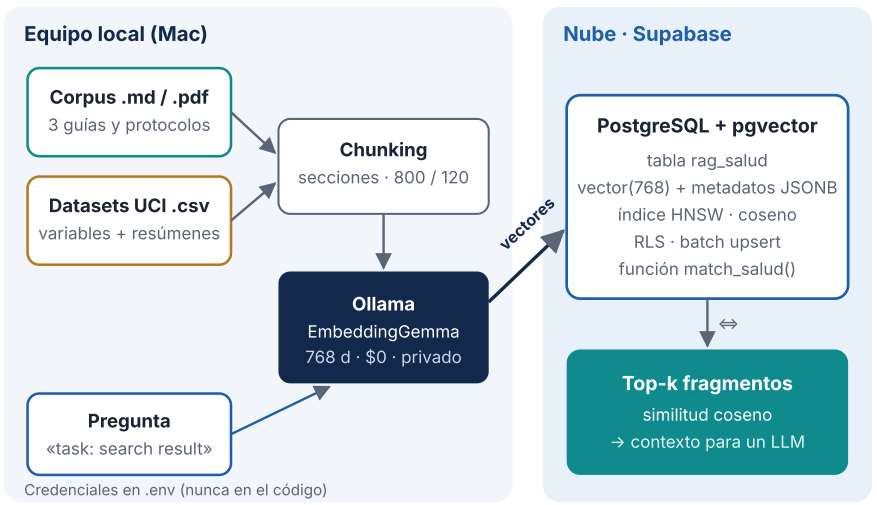
UCI Breast Cancer Wisconsin (Diagnostic) · 569 biopsias
30 características nucleares de imágenes de BACAF; 212 malignas y 357 benignas. De ambos datasets se indexan el **diccionario de variables** y **resúmenes estadísticos** en texto.

5 Chunking: 800 caracteres, 120 de solapamiento

Tamaño	Overlap	Chunks	Long. media	% < 150 car.
300	45	87	195	27,6
500	75	52	325	7,7
800	**120**	**37**	**457**	**2,7**
1200	180	30	565	0,0

Primero se divide por secciones (##) y luego con `RecursiveCharacterTextSplitter`. Con 800 cada fragmento conserva un criterio completo (umbral + interpretación); con 300 casi un tercio de fragmentos queda sin contexto y con 1.200 se mezclan temas. Total indexado: **72 vectores** (37 de documentos + 35 de datasets).

6 Arquitectura cloud



7 Stack tecnológico

Base vectorial cloud	**Supabase** (PostgreSQL gestionado, plan gratuito) + **pgvector**: índice HNSW (m = 16, ef_construction = 64), distancia coseno, RLS activo.
Embeddings	**EmbeddingGemma** (Google, ~300 M parámetros, multilingüe, 768 d) servido localmente con **Ollama**; prefijos de tarea para documento y consulta.
Chunking	LangChain `RecursiveCharacterTextSplitter` por secciones.
Ingesta	pandas (CSV), pypdf (PDF), Markdown por secciones.
Carga	psycopg 3 + pgvector: lotes de 100, `ON CONFLICT` idempotente, limpieza de obsoletos.
Entorno	Jupyter Lab local · Python 3 · variables de entorno (.env).
Costo	**$0**: sin cuotas de API de IA; la tabla ocupa ~2 MB de los 500 MB gratuitos.

8 Ejemplos de consultas semánticas

Consulta en lenguaje natural	Fragmento Top-1 recuperado	Sim. coseno
¿Qué cifras de presión arterial se consideran hipertensión?	se completa al ejecutar el notebook	—
¿Cada cuánto debe hacerse una mamografía de tamización y a qué edad?	se completa al ejecutar el notebook	—
¿Qué porcentaje de pacientes asintomáticos tiene enfermedad coronaria en los datos?	se completa al ejecutar el notebook	—
¿Qué debo hacer si me pincho con una aguja usada en una biopsia?	se completa al ejecutar el notebook	—

Control negativo (fuera de dominio): «¿Cuál es la receta de la bandeja paisa?» → similitud Top-1 = —.

9 Validación cuantitativa (10 consultas)

—
Hit@1 · fuente correcta en 1.ª posición

—
Hit@5 · fuente correcta en el Top-5

—
MRR · rango recíproco medio

—
Similitud coseno Top-1 (media)

—
Brecha vs. pregunta fuera de dominio

—
Latencia por consulta (— embedding + — Supabase)

Conclusión: la arquitectura híbrida recupera el fragmento pertinente con baja latencia y sin costo de API; la brecha frente al control negativo permite fijar un umbral para que el asistente responda «no tengo información» en lugar de inventar. Siguiente paso: generar la respuesta con un LLM citando la fuente.

Enlaces

Repositorio: **https://github.com/usuario/ESP-rag**

Video de sustentación: **https://youtu.be/xxxxxxxx**

Notebook: notebooks/ACA1_RAG_Salud_Ollama_pgvector.ipynb

Referencias (APA 7)

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart Disease* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474. https://arxiv.org/abs/2005.11401

Malkov, Y. A., & Yashunin, D. A. (2020). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 42*(4), 824–836. https://doi.org/10.1109/TPAMI.2018.2889473

Ministerio de Salud y Protección Social. (2013). *Guía de práctica clínica para la detección temprana, tratamiento integral, seguimiento y rehabilitación del cáncer de mama*. MinSalud.

Organización Mundial de la Salud. (2018). *HEARTS: Paquete técnico para el manejo de las enfermedades cardiovasculares en la atención primaria de salud*. OMS.

Supabase. (2024). *pgvector: Embeddings and vector similarity* [Documentación]. https://supabase.com/docs/guides/database/extensions/pgvector

Vera, H. S., Dua, S., Zhang, B., Salz, D., Mullins, R., ... (2025). *EmbeddingGemma: Powerful and lightweight text representations*. arXiv. https://arxiv.org/abs/2509.20354

Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1995). *Breast Cancer Wisconsin (Diagnostic)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B